

Na forma da f.e. de dispersão, temos que $\theta = \log \mu$, $l(\theta) = \log(\mu) = e^\theta$, $\phi = 1$. Usando $\eta = \log \mu$, $\mu = e^\eta$, e assim

$$w_i = \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \cdot \frac{1}{V(\mu_i)} = e^{2\eta_i} \cdot \frac{1}{\mu_i} = \frac{e^{2 \log \mu_i}}{\mu_i} = \frac{e^{\log \mu_i^2}}{\mu_i} = \frac{\mu_i^2}{\mu_i} = \mu_i.$$

$$\begin{aligned} W &= \text{diag}\{\mu_1, \dots, \mu_n\} = \text{diag}\{e^{\beta_1 + \beta_2 x_1}, \dots, e^{\beta_1 + \beta_2 x_n}\} \\ \tilde{Z} &= \tilde{\eta} + W^{-1/2} \text{diag}\{\mu_1^{-1/2}, \dots, \mu_n^{-1/2}\} (Y - \mu) \\ &= (\beta_1 + \beta_2 x_1, \dots, \beta_1 + \beta_2 x_n)^T + \text{diag}\{e^{\beta_1 + \beta_2 x_1}, \dots, e^{\beta_1 + \beta_2 x_n}\}^{-1/2} \text{diag}\{e^{\beta_1 + \beta_2 x_1}, \dots, e^{\beta_1 + \beta_2 x_n}\}^{-1/2} \left[(y_1, \dots, y_n)^T - (e^{\beta_1 + \beta_2 x_1}, \dots, e^{\beta_1 + \beta_2 x_n})^T \right]. \end{aligned}$$

Implementando no R, temos que as 3 primeiras iterações do algoritmo resultam nas seguintes estimativas:

— ITERAÇÃO 1

$$\hat{\beta}_0 = -0,9458014 \quad \hat{\beta}_1 = 0,9943552$$

— ITERAÇÃO 2

$$\hat{\beta}_0 = -1,801899 \quad \hat{\beta}_1 = 0,9793909$$

— ITERAÇÃO 3

$$\hat{\beta}_0 = -2,434624 \quad \hat{\beta}_1 = 0,9413631$$

O algoritmo convergiu para os seguintes valores, a partir da 10ª iteração:

$$\hat{\beta}_0 = -0,9547503 \quad \hat{\beta}_1 = 0,4928888$$

Assim, temos um modelo expresso da seguinte maneira:

$$\hat{Y}_i = e^{-0,9547503 + 0,4928888 x_i}.$$

Substituindo os valores de x_i , vemos que as estimativas para y_i são bem próximas do observado, resultando em um baixo valor para a soma de quadrados residuais.