

CC0293 - Análise Multivariada
Notas de aula sobre vetores aleatórios
Prof. Gualberto Agamez Montalvo

1 Vetores aleatórios

1.1 Notação e conceitos básicos

Definição 1.1. Seja \mathbf{y} um vetor aleatório de p ($p > 1$) variáveis medidas em uma unidade amostral (sujeito ou objeto). Se houver n indivíduos na amostra, os n vetores de observações são denotados por

$$\mathbf{Y}_{n \times p} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n)^\top = \begin{bmatrix} y_{11} & y_{12} & \dots & y_{1p} \\ y_{21} & y_{22} & \dots & y_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \dots & y_{np} \end{bmatrix} = [y_{ij}],$$

em que

$$\mathbf{y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \vdots \\ y_{ip} \end{bmatrix},$$

para $i = 1, 2, \dots, n$ representa a informação ou medições do i -ésimo individuo da amostra.

Exemplo 1.1. Em um estudo foi considerada uma amostra de 5 pessoas do Nordeste do Brasil com idades entre 18 e 25 anos, com o objetivo de investigar algumas variáveis antropométricas que podem estar associadas ao estado de saúde e ao perfil físico da população. A Tabela 1 apresenta os dados coletados associados as variáveis de interesse:

- y_1 : altura (em centímetros);
- y_2 : diâmetro da cintura (em centímetros);
- y_3 : diâmetro do pescoço (em centímetros).

i	y_1	y_2	y_3
1	168	82	37
2	175	90	39
3	160	78	35
4	180	85	40
5	165	80	36

Tabela 1: Dados antropométricos da amostra do Nordeste do Brasil.

Neste exemplo temos que $p = 3$ e $n = 5$, portanto, os dados podem ser representado como

$$\mathbf{Y} = \begin{bmatrix} 168 & 82 & 37 \\ 175 & 90 & 39 \\ 160 & 78 & 35 \\ 180 & 85 & 40 \\ 165 & 80 & 36 \end{bmatrix}$$

Definição 1.2. Seja uma amostra aleatória $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ em \mathbb{R}^p , então a média amostral é definida por

$$\bar{\mathbf{y}}_{\cdot} = \frac{\sum_{i=1}^n \mathbf{y}_i}{n} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n = \begin{bmatrix} \bar{y}_{\cdot 1} \\ \bar{y}_{\cdot 2} \\ \vdots \\ \bar{y}_{\cdot p} \end{bmatrix},$$

em que $\bar{y}_{\cdot k}$ representa a média amostral da k -ésima variável.

Exemplo 1.2. Continuando com o Exemplo 1.1 temos que

$$\bar{\mathbf{y}}_{\cdot} = \begin{bmatrix} 168 & 175 & 160 & 180 & 165 \\ 82 & 90 & 78 & 85 & 80 \\ 37 & 39 & 35 & 40 & 36 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \frac{1}{5} \begin{bmatrix} 848 \\ 415 \\ 187 \end{bmatrix} = \begin{bmatrix} 169,6 \\ 83,0 \\ 37,4 \end{bmatrix}.$$

No R, temos que:

```

1 > Y <- matrix(c(168, 82, 37,      # Indivíduo 1
2 +                  175, 90, 39,      # Indivíduo 2
3 +                  160, 78, 35,      # Indivíduo 3
4 +                  180, 85, 40,      # Indivíduo 4
5 +                  165, 80, 36),    # Indivíduo 5
6 +                  nrow = 5, byrow = TRUE)
7 >
8 > # Opção 1
9 > apply(Y, 2, mean)
10 [1] 169.6 83.0 37.4
11 >
12 > # Opção 2
13 > n <- 5
14 > t(Y) %*% rep(1/n, n)
15      [,1]
16 [1,] 169.6
17 [2,] 83.0
18 [3,] 37.4
19 >
20 > # Opção 3
21 > apply(Y, 2, sum)/n
22 [1] 169.6 83.0 37.4

```

Definição 1.3. A média de y sobre todos os valores da população é denominada vetor de médias populacionais ou valor esperado de y . Este é definido como o vetor de valores esperados de cada variável

$$\mathbb{E}(\mathbf{y}) = \mathbb{E} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} = \begin{bmatrix} \mathbb{E}(y_1) \\ \mathbb{E}(y_2) \\ \vdots \\ \mathbb{E}(y_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \boldsymbol{\mu},$$

em que μ_k é a média populacional da k -ésima variável.

Observação: o valor esperado de \bar{y}_{\cdot} é dado por

$$\mathbb{E}(\bar{y}_{\cdot}) = \mathbb{E} \begin{bmatrix} \bar{y}_{\cdot 1} \\ \bar{y}_{\cdot 2} \\ \vdots \\ \bar{y}_{\cdot p} \end{bmatrix} = \begin{bmatrix} \mathbb{E}(\bar{y}_{\cdot 1}) \\ \mathbb{E}(\bar{y}_{\cdot 2}) \\ \vdots \\ \mathbb{E}(\bar{y}_{\cdot p}) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \boldsymbol{\mu}.$$

Definição 1.4. A matriz de variâncias e covariâncias amostrais é dada por

$$\mathbf{S}_p = \mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \dots & S_{1p} \\ S_{21} & S_{22} & \dots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \dots & S_{pp} \end{bmatrix},$$

em que o k -ésimo elemento da diagonal é dado por

$$S_{kk} = S_k^2 = \frac{1}{n-1} \sum_{i=1}^n (y_{ik} - \bar{y}_{\cdot k})^2$$

e a covariância amostral entre as variáveis k -ésima e l -ésima é dada por

$$S_{kl} = \frac{1}{n-1} \sum_{i=1}^n (y_{ik} - \bar{y}_{\cdot k})(y_{il} - \bar{y}_{\cdot l}).$$

Exemplo 1.3. Continuando com o Exemplo 1.1 temos que

$$\mathbf{S} = \begin{bmatrix} 63,30 & 30,50 & 16,45 \\ 30,50 & 22,00 & 8,25 \\ 16,45 & 8,25 & 4,30 \end{bmatrix}.$$

No R, temos que:

```

1 > S <- var(Y); S
2      [,1]  [,2]  [,3]
3 [1,] 63.30 30.50 16.45
4 [2,] 30.50 22.00  8.25
5 [3,] 16.45  8.25  4.30

```

Observação: A matriz de covariâncias amostrais pode ser reescrita em termos dos vetores \mathbf{y}_i como

$$\begin{aligned}
\mathbf{S} &= \frac{1}{n-1} \left[\sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}_.) (\mathbf{y}_i - \bar{\mathbf{y}}_.)^\top \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n (\mathbf{y}_i \mathbf{y}_i^\top - \bar{\mathbf{y}}_+ \mathbf{y}_i^\top - \mathbf{y}_i \bar{\mathbf{y}}_+^\top + \bar{\mathbf{y}}_+ \bar{\mathbf{y}}_+^\top) \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^\top - n \bar{\mathbf{y}}_+ \bar{\mathbf{y}}_+^\top - n \bar{\mathbf{y}}_+ \bar{\mathbf{y}}_+^\top + n \bar{\mathbf{y}}_+ \bar{\mathbf{y}}_+^\top \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^\top - n \bar{\mathbf{y}}_+ \bar{\mathbf{y}}_+^\top \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^\top - \frac{(\sum_{i=1}^n \mathbf{y}_i) (\sum_{i=1}^n \mathbf{y}_i)^\top}{n} \right].
\end{aligned}$$

Adicionalmente, a matriz de covariâncias amostrais pode ser reescrita em termos da matriz \mathbf{Y} como

$$\begin{aligned}
\mathbf{S} &= \frac{1}{n-1} \mathbf{Y}^\top \mathbf{Y} - \frac{1}{n} \mathbf{Y}^\top \mathbf{J} \mathbf{Y} \\
&= \frac{1}{n-1} \mathbf{Y}^\top \left[\mathbf{I}_n - \frac{1}{n} \mathbf{J}_n \right] \mathbf{Y}
\end{aligned}$$

em que a matriz $\mathbf{I}_n - \frac{1}{n} \mathbf{J}_n$ é conhecida como matriz de projeção.

Propriedades:

1. $\mathbf{I}_n - \frac{1}{n}\mathbf{J}_n$ é simétrica e idempotente;
2. $\text{rk}(\mathbf{I}_n - \frac{1}{n}\mathbf{J}_n) = \text{tr}(\mathbf{I}_n - \frac{1}{n}\mathbf{J}_n) = n - 1$.

No R, temos que:

```

1 > J <- matrix(1, ncol = n, nrow = n)
2 > I <- diag(n)
3 > t(Y) %*% (I - J/n) %*% Y / (n-1)
4      [,1]  [,2]  [,3]
5 [1,] 63.30 30.50 16.45
6 [2,] 30.50 22.00  8.25
7 [3,] 16.45  8.25  4.30

```

Definição 1.5. A matriz de covariância populacional associada ao vetor \mathbf{y} é definida por

$$\Sigma = \text{Cov}(\mathbf{y}) = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_p^2 \end{bmatrix}$$

em que σ_k^2 é a variância populacional da k -ésima variável e σ_{kl} é a covariância populacional entre as variáveis k -ésima e l -ésima.

Observação: a matriz de covariância populacional pode ser obtida por

$$\begin{aligned}
\Sigma &= \mathbb{E} \left[(\mathbf{y} - \boldsymbol{\mu})(\mathbf{y} - \boldsymbol{\mu})^\top \right] \\
&= \mathbb{E} \left(\mathbf{y}\mathbf{y}^\top - \boldsymbol{\mu}\mathbf{y}^\top - \mathbf{y}\boldsymbol{\mu}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \right) \\
&= \mathbb{E} \left(\mathbf{y}\mathbf{y}^\top \right) - \boldsymbol{\mu}\mathbb{E} \left(\mathbf{y} \right)^\top - \mathbb{E} \left(\mathbf{y} \right) \boldsymbol{\mu}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\
&= \mathbb{E} \left(\mathbf{y}\mathbf{y}^\top \right) - \boldsymbol{\mu}\boldsymbol{\mu}^\top - \boldsymbol{\mu}\boldsymbol{\mu}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\
&= \mathbb{E} \left(\mathbf{y}\mathbf{y}^\top \right) - \boldsymbol{\mu}\boldsymbol{\mu}^\top.
\end{aligned}$$

Definição 1.6. A matriz de correlações amostrais é dada por

$$\mathbf{R} = \mathbf{D}_s^{-\frac{1}{2}} \mathbf{S} \mathbf{D}_s^{-\frac{1}{2}} = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & 1 \end{bmatrix},$$

em que $\mathbf{D}_s = \text{diag}(\mathbf{S}) = \text{diag}(S_{kk}) = \text{diag}(S_{11}, S_{22}, \dots, S_{pp}) = \text{diag}(S_1^2, S_2^2, \dots, S_p^2) = \text{diag}(S_k^2)$, $\mathbf{D}_s^{-\frac{1}{2}} = \text{diag}\left(\frac{1}{S_1}, \frac{1}{S_2}, \dots, \frac{1}{S_p}\right)$ e

$$r_{kl} = \frac{S_{kl}}{\sqrt{S_k S_l}},$$

em que, r_{kl} representa a correlação amostral entre as variáveis k -ésima e l -ésima.

Exemplo 1.4. Continuando com o Exemplo 1.1 temos que

$$\mathbf{R} \approx \begin{bmatrix} 1,0000 & 0,8173 & 0,9971 \\ 0,8173 & 1,0000 & 0,8482 \\ 0,9971 & 0,8482 & 1,0000 \end{bmatrix}.$$

No R, temos que:

```

1 > # Opção 1
2 > round(cor(Y), 4)
      [,1]   [,2]   [,3]
[1,] 1.0000 0.8173 0.9971
[2,] 0.8173 1.0000 0.8482
[3,] 0.9971 0.8482 1.0000
7 >
8 > # Opção 2
9 >
10> d <- diag(var(Y))
11> Ds <- diag(d); Ds

```

```

1      [,1] [,2] [,3]
2 [1,] 63.3    0   0.0
3 [2,] 0.0     22  0.0
4 [3,] 0.0     0   4.3
5 >
6 > round( solve(sqrt(Ds))%*%S%*%solve(sqrt(Ds))), 4)
7      [,1] [,2] [,3]
8 [1,] 1.0000 0.8173 0.9971
9 [2,] 0.8173 1.0000 0.8482
10 [3,] 0.9971 0.8482 1.0000

```

Definição 1.7. A matriz de correlações populacionais é dada por

$$\mathbf{P} = \mathbf{D}_{\Sigma}^{-\frac{1}{2}} \Sigma \mathbf{D}_{\Sigma}^{-\frac{1}{2}} = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ \rho_{21} & 1 & \dots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \dots & 1 \end{bmatrix},$$

em que $\mathbf{D}_{\Sigma} = \text{diag}(\sigma_k^2)$, $\mathbf{D}_{\Sigma}^{-\frac{1}{2}} = \text{diag}\left(\frac{1}{\sigma_k}\right)$ e

$$\rho_{kl} = \frac{\sigma_{kl}}{\sigma_k \sigma_l}.$$

Observação: as matrizes de variâncias e covariâncias \mathbf{S} e Σ podem ser obtidas por

$$\mathbf{S} = \mathbf{D}_s^{\frac{1}{2}} \mathbf{R} \mathbf{D}_s^{\frac{1}{2}}$$

e

$$\Sigma = \mathbf{D}_{\Sigma}^{\frac{1}{2}} \mathbf{P} \mathbf{D}_{\Sigma}^{\frac{1}{2}},$$

em que $\mathbf{D}_s^{\frac{1}{2}} = \text{diag}(S_k)$ e $\mathbf{D}_{\Sigma}^{\frac{1}{2}} = \text{diag}(\sigma_k)$.

1.2 Vetores de médias e matrizes de covariâncias para subconjuntos de variáveis

Definição 1.8. Considere o vetor \mathbf{y} particionado por

$$\mathbf{y} = \begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_q \end{bmatrix},$$

em que \mathbf{y}_i é de tamanho p_i para $i = 1, 2, \dots, q$ e $p = p_1 + p_2 + \dots + p_q$. Então, o vetor de médias amostrais e a matriz de covariâncias para uma amostra aleatória são dados por

$$\bar{\mathbf{y}} = \begin{bmatrix} \bar{\mathbf{y}}_1 \\ \bar{\mathbf{y}}_2 \\ \vdots \\ \bar{\mathbf{y}}_q \end{bmatrix}$$

e

$$\mathbf{S} = \begin{bmatrix} \mathbf{S}_{11} & \mathbf{S}_{12} & \dots & \mathbf{S}_{1q} \\ \mathbf{S}_{21} & \mathbf{S}_{22} & \dots & \mathbf{S}_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{S}_{q1} & \mathbf{S}_{q2} & \dots & \mathbf{S}_{qq} \end{bmatrix},$$

em que a submatriz \mathbf{S}_{kl} contém as variâncias e covariâncias das variáveis \mathbf{y}_k e \mathbf{y}_l . Os valores populacionais correspondentes são

$$\boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \\ \vdots \\ \boldsymbol{\mu}_q \end{bmatrix}$$

e

$$\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} & \dots & \boldsymbol{\Sigma}_{1q} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} & \dots & \boldsymbol{\Sigma}_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ \boldsymbol{\Sigma}_{q1} & \boldsymbol{\Sigma}_{q2} & \dots & \boldsymbol{\Sigma}_{qq} \end{bmatrix}.$$

1.3 Distâncias entre vetores

Definição 1.9. Considere dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$. A distância euclidiana quadrática é dada por

$$d_E^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top (\mathbf{x} - \mathbf{y}) = \sum_{k=1}^p (x_k - y_k)^2.$$

Exemplo 1.5. Considere os vetores:

$$\mathbf{x} = (4, 9, 5, 1)^\top \quad \text{e} \quad \mathbf{y} = (6, 8, 0, 4)^\top.$$

```

1 > x <- c(4, 9, 5, 1)
2 > y <- c(6, 8, 0, 4)
3
4 > t(x-y)%*%t(x-y)
5      [,1]
6 [1,]    39
7
8 > dist(rbind(x, y), method = "euclidean")^2
9
10 y 39

```

Observação: a função *dist* tem outras distâncias programadas

1. maximum;
2. manhattan;
3. canberra;
4. binary;
5. minkowski.

Definição 1.10. Considere dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ e \mathbf{S} a matriz de covariâncias amostrais. A distância euclidiana padronizada quadrática é dada por

$$d_{EP}^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{D}^{-1}(\mathbf{x} - \mathbf{y}) = \sum_{k=1}^p \frac{(x_k - y_k)^2}{S_{kk}},$$

em que $\mathbf{D} = \text{diag}(\mathbf{S})$.

Definição 1.11. Considere dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ e \mathbf{S} a matriz de covariâncias amostrais. A distância generalizada de Mahalanobis é dada por

$$d_{GM}^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{S}^{-1}(\mathbf{x} - \mathbf{y}).$$

Definição 1.12. Considere dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ e uma matriz \mathbf{A} positiva definidas. A expressão geral para a distância quadrática é dada por

$$d_A^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{A}(\mathbf{x} - \mathbf{y}),$$

em que \mathbf{A} é chamada de métrica.

1.4 Combinações lineares de variáveis

Definição 1.13. Considere as constantes a_1, a_2, \dots, a_p . Uma combinação linear de elementos do vetor \mathbf{y} é dada por

$$z = a_1 y_1 + a_2 y_2 + \dots + a_p y_p = \mathbf{a}^\top \mathbf{y},$$

em que $\mathbf{a} = (a_1, a_2, \dots, a_p)^\top$.

Definição 1.14. Considere as constantes a_1, a_2, \dots, a_p e uma amostra aleatória de vetor \mathbf{y}_i com $i = 1, 2, \dots, n$. A média e variância amostrais de z são dadas por

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i = \mathbf{a}^\top \bar{\mathbf{y}}.$$

e

$$s_z^2 = \frac{\sum_{i=1}^n (z_i - \bar{z})^2}{n - 1} = \mathbf{a}^\top \mathbf{S} \mathbf{a},$$

em que $\mathbf{a} = (a_1, a_2, \dots, a_p)^\top$.

Definição 1.15. Considere $z = \mathbf{a}^\top \mathbf{y}$ e $w = \mathbf{b}^\top \mathbf{y}$, então a covariância e a correlação amostrais de z e w são dadas por

$$s_{zw} = \frac{\sum_{i=1}^n (z_i - \bar{z})(w_i - \bar{w})}{n - 1} = \mathbf{a}^\top \mathbf{S} \mathbf{b},$$

e

$$r_{zw} = \frac{s_{zw}}{\sqrt{s_z^2 s_w^2}} = \frac{\mathbf{a}^\top \mathbf{S} \mathbf{b}}{\sqrt{(\mathbf{a}^\top \mathbf{S} \mathbf{a})(\mathbf{b}^\top \mathbf{S} \mathbf{b})}},$$

respectivamente.

Observação: A média e variância populacionais associados a z são dadas por

$$\mathbb{E}(z) = \mathbb{E}(\mathbf{a}^\top \mathbf{y}) = \mathbf{a}^\top \mathbb{E}(\mathbf{y}) = \mathbf{a}^\top \boldsymbol{\mu}$$

e

$$\sigma_z^2 = \text{Var}(\mathbf{a}^\top \mathbf{y}) = \mathbf{a}^\top \text{Var}(\mathbf{y}) \mathbf{a} = \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}.$$

Observação: A covariância e correlação populacionais associados a z e w são dadas por

$$\sigma_{zw} = \text{Cov}(z, w) = \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{b}$$

e

$$\rho_{zw} = \frac{\sigma_{zw}}{\sigma_z \sigma_w} = \frac{\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{b}}{\sqrt{(\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a})(\mathbf{b}^\top \boldsymbol{\Sigma} \mathbf{b})}}.$$

Definição 1.16. Considere q transformações lineares, tais que

$$z_1 = a_{11}y_1 + a_{12}y_2 + \cdots + a_{1p}y_p = \mathbf{a}_1^\top \mathbf{y}$$

$$z_2 = a_{21}y_1 + a_{22}y_2 + \cdots + a_{2p}y_p = \mathbf{a}_2^\top \mathbf{y}$$

⋮

$$z_q = a_{q1}y_1 + a_{q2}y_2 + \cdots + a_{qp}y_p = \mathbf{a}_q^\top \mathbf{y}$$

A forma matricial é dada por

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_q \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_q^\top \mathbf{y} \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_q^\top \end{bmatrix} \mathbf{y} = \mathbf{A}\mathbf{y},$$

em que $\mathbf{A}_{q \times p}$.

Definição 1.17. O vetor de médias e a matriz de covariâncias amostrais do vetor \mathbf{z} são dados por

$$\bar{\mathbf{z}} = \begin{bmatrix} \mathbf{a}_1^\top \bar{\mathbf{y}} \\ \mathbf{a}_2^\top \bar{\mathbf{y}} \\ \vdots \\ \mathbf{a}_q^\top \bar{\mathbf{y}} \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_q^\top \end{bmatrix} \bar{\mathbf{y}} = \mathbf{A}\bar{\mathbf{y}}$$

e

$$\begin{aligned} \mathbf{S}_\mathbf{z} &= \begin{bmatrix} \mathbf{a}_1^\top \mathbf{S}_y \mathbf{a}_1 & \mathbf{a}_1^\top \mathbf{S}_y \mathbf{a}_2 & \dots & \mathbf{a}_1^\top \mathbf{S}_y \mathbf{a}_q \\ \mathbf{a}_2^\top \mathbf{S}_y \mathbf{a}_1 & \mathbf{a}_2^\top \mathbf{S}_y \mathbf{a}_2 & \dots & \mathbf{a}_2^\top \mathbf{S}_y \mathbf{a}_q \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_q^\top \mathbf{S}_y \mathbf{a}_1 & \mathbf{a}_q^\top \mathbf{S}_y \mathbf{a}_2 & \dots & \mathbf{a}_q^\top \mathbf{S}_y \mathbf{a}_q \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_q^\top \end{bmatrix} [\mathbf{S}_y \mathbf{a}_1, \mathbf{S}_y \mathbf{a}_2, \dots, \mathbf{S}_y \mathbf{a}_q] \\ &= \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_q^\top \end{bmatrix} \mathbf{S}_y [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_q] = \mathbf{A} \mathbf{S}_y \mathbf{A}^\top \end{aligned}$$

Observação: O vetor de médias e a matriz de covariâncias populacionais associados ao vetor \mathbf{z} são dados por

$$\mathbb{E}(\mathbf{z}) = \mathbb{E}(\mathbf{Ay}) = \mathbf{A}\mathbb{E}(\mathbf{y}) = \mathbf{A}\boldsymbol{\mu}$$

e

$$\Sigma_z = \text{Cov}(\mathbf{Ay}) = \mathbf{ACov}(\mathbf{y})\mathbf{A}^\top = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Observação: no caso geral em que $\mathbf{z} = \mathbf{Ay} \pm \mathbf{b}$, o vetor de médias e a matriz de covariâncias populacionais são dados por

$$\mathbb{E}(\mathbf{z}) = \mathbf{A}\mathbb{E}(\mathbf{y}) \pm \mathbf{b} = \mathbf{A}\boldsymbol{\mu} \pm \mathbf{b}$$

e

$$\Sigma_z = \text{Cov}(\mathbf{Ay} \pm \mathbf{b}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

1.5 Variâncias generalizadas

A matriz de variâncias e covariâncias amostrais contém p variâncias e $\frac{p(p-1)}{2}$ covariâncias (usuamente todas são diferentes). Quando p é grande é difícil obter conclusões gerais a partir destes parâmetros. Portanto, é desejável atribuir um único valor (resumo) para expressar a variação representada por \mathbf{S} . Duas medidas usuais para resolver este problema são o determinante e o traço da matriz de covariâncias.

Definição 1.18. A variância generalizada amostral (VGA) para as variáveis não padronizadas é definida como o determinante da matriz de covariância amostral

$$\text{VGA} = |\mathbf{S}| = \prod_{k=1}^p \lambda_k,$$

em que λ_k para $k = 1, 2, \dots, p$, são os autovalores de \mathbf{S} .

Observação: se $\lambda_k = 0$ para algum $k = 1, 2, \dots, p$, então $|\mathbf{S}| = 0$. Um autovalor zero indica uma redundância no relacionamento linear das variáveis, isto é, existe dependência linear. Uma solução para este dilema é remover uma ou mais variáveis.

Definição 1.19. A variância generalizada amostral para as variáveis padronizadas é definida como o determinante da matriz de correlação amostral.

Observação: a relação entre $|\mathbf{S}|$ e $|\mathbf{R}|$ é dada por

$$\begin{aligned} |\mathbf{R}| &= |\mathbf{D}_s^{-\frac{1}{2}} \mathbf{S} \mathbf{D}_s^{-\frac{1}{2}}| = |\mathbf{D}_s^{-\frac{1}{2}}| |\mathbf{S}| |\mathbf{D}_s^{-\frac{1}{2}}| \\ &= \prod_{k=1}^p \frac{1}{s_k} \times |\mathbf{S}| \times \prod_{k=1}^p \frac{1}{s_k} \\ &= |\mathbf{S}| \prod_{k=1}^p \frac{1}{s_k^2}, \end{aligned}$$

e

$$|\mathbf{S}| = |\mathbf{R}| \prod_{k=1}^p s_k^2.$$

Definição 1.20. A variância total amostral (VTA) para as variáveis não padronizadas é definida como o traço da matriz de covariância amostral

$$\text{VTA} = \text{tr}(\mathbf{S}) = \sum_{k=1}^p s_k^2 = \sum_{k=1}^p \lambda_k.$$

Atividade

Pesquisar:

1. Interpretação geométrica da variância generalizada;
2. Matriz raiz quadrada;
3. Decomposição em valor singular.