

## 1. Consistência

O Vladison (turma 22.2) na última aula me pediu para resolver um exercício sobre a consistência de um estimador.

Esta pergunta gerou a seguinte aula. Vamos aproveitar?

**Definição:** Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória de uma variável aleatória de  $X$  que depende de um parâmetro  $\theta$

Dizemos que o estimador  $T_n = h(x_1, X_2, \dots, X_n)$  é consistente para  $\theta$  se para todo  $\epsilon > 0$  temos:

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| > \epsilon) = 0.$$

Dizemos também que  $T_n$  converge em probabilidade para  $\theta$ .

**Exemplo 1:** Seja  $X$  uma variável aleatória  $X$  com  $E(X) = \theta$  e  $V(X) = \sigma^2$ . Considere  $X_1, X_2, \dots, X_n$  uma amostra aleatória de uma variável aleatória de  $X$ .

Mostre que  $\bar{X}$  é um consistente para  $\theta$ .

Devemos provar que

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \theta| > \epsilon) = 0.$$

Sabemos que:

$$E(\bar{X}) = \theta \quad e \quad Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Vamos aplicar a desigualdade de Chebyshev:

$$P(|\bar{X} - \theta| > \epsilon) \leq \frac{V(\bar{X})}{\epsilon^2} = \frac{\frac{\sigma^2}{n}}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}$$

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \theta| > \epsilon) = \sigma^2 \lim_{n \rightarrow \infty} \frac{1}{n} = 0.$$

Provando assim a consistência de  $\bar{X}$ .

Vamos provar que a consistência de  $T_n$  também pode ser definida como:

- i.  $T_n$  é um estimador assintoticamente não viciado para  $\theta$ , isto é,

$$\lim_{n \rightarrow \infty} E(T_n) = \theta.$$

- ii.

$$\lim_{n \rightarrow \infty} Var(T_n) = 0.$$

Vamos justificar:

$$P(|T_n - \theta| > \epsilon) = P(|T_n - \theta|^2 > \epsilon^2) = P((T_n - \theta)^2 > \epsilon^2) \leq \frac{E(T_n - \theta)^2}{\epsilon^2}.$$

Note que:

$$E(T_n - \theta)^2 = EQM(T_n) = Var(T_n) + [E(T_n) - \theta]^2.$$

Note que se as duas condições são satisfeitas então:

$$\lim_{n \rightarrow \infty} E(T_n - \theta)^2 = 0$$

provando assim a consistência de  $T_n$ .

Vamos verificar a consistência por simulação:

2. Vamos reproduzir o capítulo 22 da apostila do professor Paulo Justiniano.

Um estimador é consistente quando seu valor se aproxima do verdadeiro valor do parâmetro à medida que aumenta-se o tamanho da amostra. Vejamos como podemos ilustrar este resultado usando simulação.

A ideia básica é a seguinte:

1. escolher uma distribuição e seus parâmetros,
2. definir o estimador,
3. definir uma sequência crescente de valores de tamanho de amostras,
4. obter uma amostra de cada tamanho,
5. calcular a estatística para cada amostra,
6. fazer um gráfico dos valores das estimativas contra o tamanho de amostra, indicando neste gráfico valor verdadeiro do parâmetro.

### **Média da distribuição normal**

Seguindo os passos acima vamos:

**Passo 1:** tomar a distribuição Normal de média 10 e variância 4.

**Passo 2:** definir o estimador

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

**Passo 3:** escolhemos os tamanhos de amostra  $n = 2, 5, 10, 15, 20, \dots, 1000, 1010, 1020, \dots, 5000$ ,

**Passo 4:** fazemos os cálculos e produzimos um gráfico como mostrado na 27 com os comandos a seguir.

Veja com carinho o gráfico:

Médias de amostras de diferentes tamanhos.

Este gráfico é obtido no **R** através dos comandos:




Figura 1:

```
ns <- c(2, seq(5, 1000, by=5), seq(1010, 5000, by=10))
estim <- numeric(length(ns))
for (i in 1:length(ns)){
  amostra <- rnorm(ns[i], 10, 4)
  estim[i] <- mean(amostra)
}
plot(ns, estim)
abline(h=10,col="red")
```

#####Vamos Comentar!!!!

### 3. Momentos das distribuições amostrais de estimadores

Para Inferência Estatística é necessário conhecer a distribuição amostral dos estimadores. Em alguns casos estas distribuições são derivadas analiticamente. Isto se aplica a diversos resultados vistos em um curso de Inferência Estatística. Por exemplo seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória de

$$X \sim N(\mu, \sigma^2).$$

A distribuição da média amostral  $\bar{X}$  é:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Além disto este procedimento permite investigar distribuições amostrais que são complicadas ou não podem ser obtidas analiticamente.

Vamos ver um exemplo: Suponha que temos interesse no parâmetro:

$$\theta = \frac{\mu}{\sigma^2}.$$

Para estimar  $\theta$  vamos usar o seguinte estimador:

$$T = \frac{\bar{X}}{S^2},$$

em que  $\bar{X}$  é a média amostral e  $S^2$  a variância amostral.

Para obter por simulação a esperança e variância do estimador  $T$  devemos seguir os seguintes passos.

1. escolher uma distribuição e seus parâmetros, no caso vamos escolher uma

$$N(\mu = 180, \sigma^2 = 64),$$

2. definir um tamanho de amostra, no caso escolhemos  $n = 20$ ,
3. obter por simulação um número  $N$  de amostras, vamos usar  $N = 1000$ ,
4. calcular a estatística de interesse para cada amostra,
5. usar as amostras para obter as estimativas  $E[T]$  e  $Var[T]$ .

Vamos ver agora comandos do **R**:

```
amostras <- matrix(rnorm(20*1000, mean=180, sd=8), nc=1000)
```

```
Tvals = apply(amostras, 2, function(x) {mean(x)/var(x)})
```

```
ET_est = mean(Tvals)
```

```
ET_est
VarT_est= var(Tvals)
VarT_est
```

Nestes comandos primeiro obtemos 1000 amostras de tamanho 20 que armazenamos em uma matriz de dimensão  $20 \times 1000$ , onde cada coluna é uma amostra. A seguir usamos a função **apply** para calcular a quantidade desejada que definimos com

$$function(x) \text{ mean}(x)/var(x).$$

No caso anterior foi obtido:

Se você rodar os comandos acima deverá obter resultados um pouco diferentes (mas não muito!) pois nossas amostras da distribuição normal não são as mesmas.

Veja este fato aqui.

```
> ###Vamos rodar mais uma vez!!!!
>
>
>
> amostras <- matrix(rnorm(20*1000, mean=180, sd=8), nc=1000)
>
> Tvals = apply(amostras, 2, function(x) {mean(x)/var(x)})
>
> ET_est = mean(Tvals)
> ET_est
[1] 3.105506
> VarT_est= var(Tvals)
> VarT_est
[1] 1.259352
>
>
> ####Mais outra vez!!!!
>
>
> amostras <- matrix(rnorm(20*1000, mean=180, sd=8), nc=1000)
```

```

>
> Tvals = apply(amostras, 2, function(x) {mean(x)/var(x)})
>
> ET_est = mean(Tvals)
> ET_est
[1] 3.14434
> VarT_ = var(Tvals)
> VarT_est
[1] 1.259352
>

```

#### 4. Exercícios:

1. Estude a consistência do estimador

$$\hat{\lambda} = \frac{1}{\bar{X}},$$

para o parâmetro  $\lambda$  de  $X \sim \text{Exp}(\lambda)$ .

2. No exemplo dos momentos das distribuições de estimadores visto anteriormente ilustramos a obtenção dos momentos para um tamanho fixo de amostra  $n = 20$ . Repita o procedimento para vários tamanhos de amostra e faça um gráfico mostrando o comportamento de  $\hat{E}[T]$  e  $\hat{V}[T]$  em função de  $n$ .

3. Estime por simulação a esperança e a variância do estimador

$$\hat{\lambda} = \bar{X},$$

do parâmetro  $\lambda$  de uma Poisson para um tamanho de amostra  $n = 30$ . Compare com os valores obtidos analiticamente. Mostre em um gráfico como os valores de  $\hat{E}[\hat{\lambda}]$  e  $\hat{V}[\hat{\lambda}]$  variam em função de  $n$ .

4. Crie um exemplo para ilustrar a não tendenciosidade de estimadores.

**Sugestão:** compare os estimadores

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}, \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} = \frac{n-1}{n} S^2,$$

da variância  $\sigma^2$  de uma distribuição normal.

5. Crie um exemplo para comparar a variância de dois estimadores. Por exemplo compare por simulação as variâncias dos estimadores

$$T_1 = \bar{X} \quad e \quad T_2 = \frac{Y_n + Y_1}{2},$$

do parâmetro  $\mu$  de uma  $N(\mu, \sigma^2)$  em que

$$Y_1 = \min(X_1, X_2, \dots, X_n) \quad e \quad Y_n = \max(X_1, X_2, \dots, X_n).$$