

CC-0288 - Inferência Estatística I

Exemplo 1.3.5 - 17/03/2023

Prof. Maurício Mota

1. Vamos comentar o Exemplo 1.3.5 da página 10 do livro do Heleno e da Mônica.

Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória de  $X$  com  $E(X) = \theta$  e  $Var(X) = \sigma^2$ , em que  $\sigma^2$  é conhecido.

Consideramos agora os estimadores lineares:

$$X_L = \sum_{i=1}^n l_i X_i,$$

em que  $l_i \geq 0$ ,  $i = 1, 2, \dots, n$  são constantes conhecidas.

Vamos calcular a esperança de  $X_L$ :

$$E[X_L] = E\left[\sum_{i=1}^n l_i X_i\right] = \sum_{i=1}^n E[l_i X_i] = \sum_{i=1}^n l_i E[X_i],$$

$$E[X_L] = \sum_{i=1}^n l_i \theta = \theta \sum_{i=1}^n l_i,$$

temos  $X_L$  é um estimador não viciado para  $\theta$  se e somente se:

$$\sum_{i=1}^n l_i = 1.$$

A variância de  $X_L$  é dada por:

$$Var[X_L] = Var\left[\sum_{i=1}^n l_i X_i\right] = \sum_{i=1}^n Var[l_i X_i] = \sum_{i=1}^n l_i^2 Var[X_i],$$

$$Var[X_L] = \sum_{i=1}^n l_i^2 \sigma^2 = \sigma^2 \sum_{i=1}^n l_i^2.$$

Assim nosso problema agora como escolher os coeficientes  $l_i$  para achar um estimador não viciado com a menor variância.

Assim teremos que minimizar  $Var[X_L]$  sujeito à restrição  $\sum_{i=1}^n l_i = 1$ .

O livro apresenta duas maneiras para esta busca.

Note que

$$\bar{l} = \frac{\sum_{i=1}^n l_i}{n} = \frac{1}{n}.$$

Note que:

$$\sum_{i=1}^n (l_i - \bar{l})^2 = \sum_{i=1}^n l_i^2 - n \bar{l}^2 = \sum_{i=1}^n l_i^2 - n \frac{1}{n^2} = \sum_{i=1}^n l_i^2 - \frac{1}{n}.$$

Assim,

$$\sum_{i=1}^n l_i^2 = \sum_{i=1}^n (l_i - \bar{l})^2 + \frac{1}{n} = \sum_{i=1}^n (l_i - \frac{1}{n})^2 + \frac{1}{n} \geq \frac{1}{n}.$$

Isto só acontece quando:

$$l_i = \frac{1}{n}, i = 1, 2, \dots, n.$$

Assim

$$X_L = \sum_{i=1}^n l_i X_i = \sum_{i=1}^n \frac{1}{n} X_i = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

O estimador linear com a menor variância é a média amostral.

A segunda maneira é utilizar multiplicadores de Lagrange.

A função a ser minimizada é:

$$H(\lambda) = \sigma^2 \sum_{i=1}^n l_i^2 - \lambda \left( \sum_{i=1}^n l_i - 1 \right).$$

Derivando parcialmente em relação a  $l_j$ ,  $j = 1, 2, \dots, n$  temos:

$$2 \sigma^2 l_j - \lambda = 0$$

logo

$$l_j = \frac{\lambda}{2\sigma^2}$$

Somando para  $j = 1, 2, \dots, n$  temos:

$$1 = \sum_{j=1}^n l_j = \frac{n\lambda}{2\sigma^2}.$$

Logo

$$\lambda = \frac{2\sigma^2}{n}.$$

$$l_i = \frac{\lambda}{2\sigma^2} = \frac{\frac{2\sigma^2}{n}}{2\sigma^2} = \frac{1}{n}.$$

Assim chegamos a mesma conclusão anterior.