

CC0288 - Inferência Estatística I

Método dos Mínimos Quadrados - 14/04/2023.

Prof. Maurício

Método dos Mínimos Quadrados

Vamos analisar a seção 11.4 do livro do Bussab&Morettin.

Um dos procedimentos mais usados para obter estimadores é aquele que se baseia no princípio dos mínimos quadrados, introduzido por Gauss em 1794, mas que primeiro apareceu com esse nome no apêndice do tratado de Legendre, *Nouvelles Méthodes pour la Détermination des Orbites des Comètes*, publicado em Paris em 1806. Gauss somente viria a publicar seus resultados em 1809, em Hamburgo. Ambos utilizaram o princípio em conexão com problemas de Astronomia e Física.

Vejamos o procedimento por meio de um exemplo simples.

Exemplo 11.9 Um engenheiro está estudando a resistência Y de uma fibra em função de seu diâmetro X e notou que as variáveis são aproximadamente proporcionais, isto é, elas obedecem à relação

$$Y \approx \theta X, \quad (11.25).$$

em que θ é o coeficiente de proporcionalidade. Agora ele deseja estimar o parâmetro θ , baseado numa amostra de cinco unidades, que, submetidas a mensuração e testes, produziram os resultados:

X:	1,2	1,5	1,7	2	2,6	$\bar{X} = 1,8$
Y	3,9	4,7	5,6	5,8	7,0	$\bar{Y} = 5,4$

Vamos fazer um diagrama de dispersão :

Foi feito um pequeno programa no **R**:

```
X=c(12,15,17,20,26)/10;X
[1] 1.2 1.5 1.7 2.0 2.6
> Y=c(39,47,56,58,70)/10;Y
[1] 3.9 4.7 5.6 5.8 7.0
> n=length(Y);n
[1] 5
>
> Xb=mean(X);Xb
```

```
[1] 1.8
>
> Yb=mean(Y);Yb
[1] 5.4
>
> plot(X,Y,xlim=c(0,3),ylim=c(0,8))
> abline(a=0,b=3,col="red")
>
```




Figura 1:

O valor a é o coeficiente linear e o valor b o coeficiente angular da reta que passa pela origem. Inspeccionando os resultados, conclui-se que $\hat{\theta} = 3$ parece ser um valor razoável.

Como verificar a qualidade dessa estimativa ? Podemos utilizar o modelo

$$\hat{Y} = 3X$$

e ver como esse prevê os valores de Y , para os dados valores de X , e como são as discrepâncias entre os valores observados e os estimados pelo modelo.

Essa análise está resumida na Tabela 11.1

X	Y	$\hat{Y} = 3X$	$e = Y - \hat{Y}$	$e^2 = (Y - \hat{Y})^2$
1,2	3,9	3,6	0,3	0,09
1,5	4,7	4,5	0,2	0,04
1,7	5,6	5,1	0,5	0,25
2,0	5,8	6	-0,2	0,04
2,6	7,0	7,8	-0,8	0,64
		Total	0	1,06

Os valores da coluna $(Y - 3X) = (Y - \bar{Y})$ medem a inadequação do modelo para cada observação

da amostra, enquanto o valor é uma tentativa de medir o erro quadrático total da amostra?. Como em situações anteriores, elevou-se ao quadrado para evitar o problema do sinal.

Quanto menor for o erro quadrático total, melhor será a estimativa.

Isso nos sugere procurar a estimativa que torne mínima essa soma de quadrados. Matematicamente, o problema passa a ser o de encontrar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^5 (Y_i - \theta X_i)^2, \quad (11.26)$$

O mínimo da função é obtido derivando-a em relação a θ , e igualando o resultado a zero (ver Morettin et al., 2005), o que resulta

$$\begin{aligned} S'(\theta) &= 2 \sum_{i=1}^5 (Y_i - \theta X_i)(-X_i), \\ S'(\theta) &= -2 \sum_{i=1}^5 (X_i Y_i - \theta X_i^2) = 0 \\ S'(\theta) &= -2 \sum_{i=1}^5 X_i Y_i + 2\theta \sum_{i=1}^5 X_i^2. \end{aligned}$$

A derivada segunda de S é dada por:

$$S''(\theta) = 2 \sum_{i=1}^5 X_i^2 > 0$$

Igualando a derivada primeira a zero temos:

$$\sum_{i=1}^5 X_i Y_i - \theta \sum_{i=1}^5 X_i^2 = 0$$

Assim

$$\theta = \frac{\sum_{i=1}^5 X_i Y_i}{\sum_{i=1}^5 X_i^2},$$

que é ponto de mínimo relativo pois a derivada segunda é sempre positiva.

O estimador de mínimos quadrados de θ é dado por:

$$\hat{\theta}_{MQ} = \frac{\sum_{i=1}^5 X_i Y_i}{\sum_{i=1}^5 X_i^2}.$$

Usando os dados acima encontramos $\hat{\theta}_{MQ} = 2,94$, que conduz a um valor mínimo para $S(\theta)$ de 0,94. Observe que esse valor é realmente menor do que o observado para $\theta = 3$, ou seja, 1,06.

Vamos utilizar o **R** para calcular a estimativa de mínimos quadrados de θ bem como os valores previstos pelo modelo.

```
> X=c(12,15,17,20,26)/10;X
[1] 1.2 1.5 1.7 2.0 2.6
> Y=c(39,47,56,58,70)/10;Y
[1] 3.9 4.7 5.6 5.8 7.0
> n=length(Y);n
[1] 5
>
> SX=sum(X);SX
[1] 9
> X2=X^2
>
> SX2=sum(X2);SX2
[1] 17.34
> XY=X*Y
>
> SXY=sum(XY);SXY
[1] 51.05
>
> teta_est=SXY/SX2;teta_est
[1] 2.94406
>
> round(teta_est,2) ##Estimativa de mínimos quadrados.
[1] 2.94
>
> Y_est=teta_est*X;Y_est
[1] 3.532872 4.416090 5.004902 5.888120 7.654556
>
> e=Y-Y_est
> e2=e^2
>
> sum(e2)
[1] 1.005738
>
> tabela=cbind(X,Y,X2,XY,Y_est,e,e2);tabela
X   Y   X2   XY   Y_est      e      e2
[1,] 1.2 3.9 1.44 4.68 3.532872 0.36712803 0.134782989
[2,] 1.5 4.7 2.25 7.05 4.416090 0.28391003 0.080604908
[3,] 1.7 5.6 2.89 9.52 5.004902 0.59509804 0.354141676
[4,] 2.0 5.8 4.00 11.60 5.888120 -0.08811995 0.007765126
[5,] 2.6 7.0 6.76 18.20 7.654556 -0.65455594 0.428443479
>
```

Vamos fazer agora com uma função direta do **R**:

```
> ####Fazer direto no R:
>
>
```

```
> ###0 (-1) no comando indica que o coeficiente linear é zero!!!!!!
>
>
>
>
> mod1=lm(Y~X -1);mod1
```

```
Call:
lm(formula = Y ~ X - 1)
```

```
Coefficients:
X
2.944
```

```
>
> predict(mod1)
1      2      3      4      5
3.532872 4.416090 5.004902 5.888120 7.654556
>
>
> summary(mod1)
```

```
Call:
lm(formula = Y ~ X - 1)
```

```
Residuals:
1      2      3      4      5
0.36713 0.28391 0.59510 -0.08812 -0.65456
```

```
Coefficients:
Estimate Std. Error t value Pr(>|t|)
X    2.9441     0.1204   24.45 1.66e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.5014 on 4 degrees of freedom
Multiple R-squared:  0.9934,    Adjusted R-squared:  0.9917
F-statistic: 597.7 on 1 and 4 DF,  p-value: 1.661e-05
```

```
> anova(mod1)
Analysis of Variance Table
```

```
Response: Y
Df Sum Sq Mean Sq F value    Pr(>F)
X      1 150.294 150.294  597.75 1.661e-05 ***
Residuals  4   1.006   0.251
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
>
> #####
>
> SY2=sum(Y^2);SY2
```

```
[1] 151.3
>
> ###Observe que:
>
>
>
> 150.294 + 1.006
[1] 151.3
>
```

Como foi dito, não esperávamos uma relação perfeita entre as duas variáveis, já que o diâmetro da fibra não é o único responsável pela resistência; outros fatores não controlados afetam o resultado.

Desse modo, duas amostras obtidas do mesmo diâmetro X não teriam obrigatoriamente que apresentar o mesmo resultado Y , mas valores em torno de um valor esperado θX .

Em outras palavras, estamos supondo que, para um dado valor da variável explicativa X , os valores da variável resposta Y seguem uma distribuição de probabilidade $f_Y(y)$, centrada em θX .

Isso equivale a afirmar que, para cada X , o desvio

$$\epsilon = Y - \theta X$$

segue uma distribuição centrada no zero.

Para melhor entendimento dessa proposição, veja o Capítulo 16. Podemos, então, escrever

$$E(Y|x) = \theta x, \text{ para todo valor } x.$$

É comum supor que ϵ tem a mesma distribuição, para todo valor x da variável explicativa X . Desse modo, é comum escrever

$$Y = \theta x + \epsilon$$

, com ϵ seguindo a distribuição $f_\epsilon(\cdot)$, com média zero. Como ilustração, poderíamos supor que

$$\epsilon \sim N(0, \sigma^2), \text{ para todo } x.$$

Quanto menor for a variância σ^2 , melhor será a ?previsão? de Y como função de x . Assim, parece razoável escolher θ que torna mínima a soma dos quadrados dos erros: O modelo acima pode ser generalizado, de modo a envolver outras funções do parâmetro, resultando no modelo

$$Y = g(X; \theta) + \epsilon, \quad (11.27)$$

Note que

$$E(Y) = g(X; \theta),$$

e devemos procurar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - E(Y_i))^2 = \sum_{i=1}^n (Y_i - g(X_i; \theta))^2, \quad (11.28)$$

Para uma amostra $(X_1, Y_1), \dots, (X_n, Y_n)$ das variáveis X e Y . A solução MQ é chamada de estimador de mínimos quadrados (EMQ) de θ .

Nos Capítulos 15 e 16, voltaremos a esse tópico e trataremos com mais detalhes os chamados modelos lineares.

Suponha que

$$Y_i | X_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

com

$$\epsilon_i \sim N(0, \sigma^2), \quad i = 1, 2, \dots, n$$

Na prática usamos:

$$Y_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \dots, n.$$

Aplicando o operador esperança temos:

$$E(Y_i) = \theta X_i + E(\epsilon_i) = \theta X_i + 0 = \theta X_i.$$

Calculando a variância temos:

$$Var(Y_i) = Var(\theta X_i + \epsilon_i) = Var(\epsilon_i) = \sigma^2.$$

Considere o estimador de MQ de θ dado por:

$$\hat{\theta}_{MQ} = \frac{\sum_{i=1}^n X_i Y_i}{\sum_{i=1}^n X_i^2} = \sum_{i=1}^n w_i Y_i,$$

com

$$w_i = \frac{X_i}{\sum_{i=1}^n X_i^2}.$$

Inicialmente mostre que:

$$\sum_{i=1}^n w_i X_i = 1.$$

Prova

Temos que :

$$\sum_{i=1}^n w_i X_i = \sum_{i=1}^n \frac{X_i}{\sum_{i=1}^n X_i^2} \times X_i.$$

$$\sum_{i=1}^n w_i X_i = \frac{1}{\sum_{i=1}^n X_i^2} \sum_{i=1}^n X_i^2 = 1.$$

Agora mostre que $\hat{\theta}_{MQ}$ é um estimador não viciado de θ .

$$E(\hat{\theta}_{MQ}) = E\left(\sum_{i=1}^n w_i Y_i\right),$$

$$E(\hat{\theta}_{MQ}) = \sum_{i=1}^n E(w_i Y_i) = \sum_{i=1}^n w_i E(Y_i)$$

$$E(\hat{\theta}_{MQ}) = \sum_{i=1}^n w_i \theta X_i = \theta \sum_{i=1}^n X_i w_i$$

$$E(\hat{\theta}_{MQ}) = \theta \times 1 = \theta.$$

Agora mostre que:

$$\sum_{i=1}^n w_i^2 = \frac{1}{\sum_{i=1}^n X_i^2}.$$

Prova:

Seja

$$A = \sum_{i=1}^n X_i^2$$

Assim

$$w_i = \frac{X_i}{A}, \quad w_i^2 = \frac{X_i^2}{A^2}$$

$$\sum_{i=1}^n w_i^2 = \sum_{i=1}^n \frac{X_i^2}{A^2} = \frac{1}{A^2} \sum_{i=1}^n X_i^2$$

$$\sum_{i=1}^n w_i^2 = \frac{1}{A^2} A = \frac{1}{A} = \frac{1}{\sum_{i=1}^n X_i^2}$$

Agora mostre que a variância do estimador de mínimos quadrados de θ é dada por:

$$Var(\hat{\theta}_{MQ}) = \frac{\sigma^2}{\sum_{i=1}^n X_i^2}.$$

Prova:

$$\begin{aligned} Var(\hat{\theta}_{MQ}) &= Var\left(\sum_{i=1}^n w_i Y_i\right) = \sum_{i=1}^n Var(w_i Y_i), \\ Var(\hat{\theta}_{MQ}) &= \sum_{i=1}^n w_i^2 V(Y_i) = \sum_{i=1}^n w_i^2 \sigma^2, \\ Var(\hat{\theta}_{MQ}) &= \sigma^2 \sum_{i=1}^n w_i^2 = \frac{\sigma^2}{\sum_{i=1}^n X_i^2}. \end{aligned}$$

Qual a distribuição Amostral do estimador de mínimos quadrados $V = \hat{\theta}_{MQ}$?

Prova: Sabemos que

$$Y_i \sim N(\theta X_i, \sigma^2)$$

e sua função geradora de momentos é dada por:

$$M_{Y_i}(t) = \exp(\theta X_i t + \frac{1}{2} \sigma^2 t^2)$$

A função de momentos de V é dada por:

$$M_V(t) = E(e^{tV}) = E\left(e^{t \sum_{i=1}^n w_i Y_i}\right)$$

$$M_V(t) = E\left(e^{\sum_{i=1}^n w_i t Y_i}\right)$$

$$M_V(t) = \prod_{i=1}^n E(e^{w_i t Y_i}),$$

$$M_V(t) = \prod_{i=1}^n M_{Y_i}(w_i t)$$

$$M_V(t) = \prod_{i=1}^n \exp(\theta X_i w_i t + \frac{1}{2} \sigma^2 w_i^2 t^2)$$

$$M_V(t) = \exp\left(\theta t \sum_{i=1}^n X_i w_i + \frac{1}{2} \sigma^2 \sum_{i=1}^n w_i^2 t^2\right)$$

$$M_V(t) = \exp\left(\theta t \times 1 + \frac{1}{2} \times \sigma^2 \times \frac{1}{\sum_{i=1}^n X_i^2} t^2\right)$$

$$M_V(t) = \exp \left(\theta t + \frac{1}{2} \times \frac{\sigma^2}{\sum_{i=1}^n X_i^2} t^2 \right)$$

Assim

$$V = \hat{\theta}_{MQ} \sim N \left(\theta, \frac{\sigma^2}{\sum_{i=1}^n X_i^2} \right)$$

Qual o estimador de mínimos quadrados baseado em uma amostra aleatória de tamanho n , X_1, X_2, \dots, X_n , de uma variável X com distribuição:

- a. $X \sim \text{Poisson}(\theta)$
- b. $X \sim N(\mu, 1)$
- c. $X \sim \text{Ber}(p)$.

Solução: Devemos minimizar
Sabemos que

$$E(X_i) = \theta, \quad i = 1, 2, \dots, n.$$

$$S(\theta) = \sum_{i=1}^n (X_i - E(X_i))^2 = \sum_{i=1}^n (X_i - \theta)^2$$

$$S(\theta) = \sum_{i=1}^n X_i^2 - 2 \sum_{i=1}^n X_i \theta + n\theta^2 = a\theta^2 + b\theta + c$$

Como $a > 0$ temos

$$\theta_{min} = \frac{-b}{2a} = \frac{2 \sum_{i=1}^n X_i}{2n} = \bar{X}$$

que é o nosso estimador de mínimos quadrados.

No caso da normal temos:

Sabemos que

$$E(X_i) = \mu, \quad i = 1, 2, \dots, n.$$

$$S(\mu) = \sum_{i=1}^n (X_i - E(X_i))^2 = \sum_{i=1}^n (X_i - \mu)^2$$

$$\mu_{min} = \bar{X},$$

que é o nosso estimador de mínimos quadrados.
No caso da Bernouli temos

$$E(X_i) = p, \quad i = 1, 2, \dots, n.$$

$$S(p) = \sum_{i=1}^n (X_i - E(X_i))^2 = \sum_{i=1}^n (X_i - p)^2$$

$$S(p) = np^2 - 2 \sum_{i=1}^n X_i p + \sum_{i=1}^n X_i^2$$

$$S'(p) = 2pn - 2 \sum_{i=1}^n X_i$$

$$S''(p) = 2n > 0$$

De $S'(p) = 0$ temos

$$p_{min} = \bar{X},$$

que é o nosso estimador de mínimos quadrados.

Problemas

6. Estamos estudando o modelo $y_t = \mu + \epsilon_t$, para o qual uma amostra de cinco elementos produziu os seguintes valores para y_t : 3, 5, 6, 8, 16.

(a) Calcule os valores de

$$S(\mu) = \sum_t (y_t - \mu)^2$$

para $\mu = 6, 7, 8, 9, 10$, e faça o gráfico de $S(\mu)$ em relação a μ .

Qual o valor que parece tornar mínimo $S(\mu)$?

(b) Derivando $S(\mu)$ em relação a μ , e igualando o resultado a zero, você encontrará o EMQ de μ . Usando os dados acima, encontre a estimativa para μ e compare com o resultado do item anterior.

7. Os dados abaixo referem-se ao índice de inflação (y_t) de 1967 a 1979.

Ano(t)	1967	1969	1971	1973	1975	1977	1979
Inflação(y_t)	128	192	277	373	613	1236	2639

(a) Faça o gráfico de y_t contra t .

(b) Considere ajustar o modelo

$$y_t = \alpha + \beta t + \epsilon_t$$

aos dados. Encontre as estimativas de mínimos quadrados de α e β .

(c) Qual seria a inflação em 1981?

(d) Você teria alguma restrição em adotar o modelo linear nesse caso ?

8. No Problema 7, determinamos os estimadores de mínimos quadrados para o modelo

$$y_t = f(t) + \epsilon_t$$

, no qual

$$f(t) = \alpha + \beta t$$

.

Suponha agora que

$$f(t) = \alpha + \beta x_t, \quad t = 1, 2, \dots, n,$$

ou seja, temos n valores fixos x_1, x_2, \dots, x_n uma variável fixa (não aleatória) x_t . Obtenha os EMQ de α e β para esse modelo.

9. Aplique os resultados do Problema 8 para os dados a seguir:

t	1	2	3	4	5	6	7	8	9	10
x_t	1,5	1,8	1,6	2,5	4,0	3,8	4,5	5,1	6,5	6,0
y_t	66,8	67,0	66,9	67,6	68,9	68,7	69,3	69,8	71,0	70,6